

Curso introductorio en Matematicas y Estadistica

Programa de Finanzas Cuantitativas
QUANt



UCEMA

Probabilidad

Concepto de probabilidad - Probabilidad discreta

En la teoría de probabilidad la aleatoriedad se modela de la siguiente forma:

- Con un **espacio muestral** S que contiene todos los posibles estados que puede tomar el universo en el que queremos hacer mediciones.

Concepto de probabilidad - Probabilidad discreta

En la teoría de probabilidad la aleatoriedad se modela de la siguiente forma:

- Con un **espacio muestral** S que contiene todos los posibles estados que puede tomar el universo en el que queremos hacer mediciones.
- Con una colección F de subconjuntos de S a los que **se les puede asignar una probabilidad** de ocurrir.

Concepto de probabilidad - Probabilidad discreta

En la teoría de probabilidad la aleatoriedad se modela de la siguiente forma:

- Con un **espacio muestral** S que contiene todos los posibles estados que puede tomar el universo en el que queremos hacer mediciones.
- Con una colección F de subconjuntos de S a los que **se les puede asignar una probabilidad** de ocurrir.
- Con una **función de probabilidad** P que asigna a cada subconjunto de S presente en F un valor entre 0 y 1 que representa su probabilidad de ocurrir.

Concepto de probabilidad - Probabilidad discreta

En la teoría de probabilidad la aleatoriedad se modela de la siguiente forma:

- Con un **espacio muestral** S que contiene todos los posibles estados que puede tomar el universo en el que queremos hacer mediciones.
- Con una colección F de subconjuntos de S a los que **se les puede asignar una probabilidad** de ocurrir.
- Con una **función de probabilidad** P que asigna a cada subconjunto de S presente en F un valor entre 0 y 1 que representa su probabilidad de ocurrir.

Importante: para definir un espacio de probabilidad, S , F y P deben cumplir ciertas propiedades. Fuera de esto, las elecciones son completamente arbitrarias, y cada elección representará una forma distinta de modelar el problema que nos interese.

Concepto de probabilidad

Las propiedades que deben cumplirse son:

F1. $S \in F$.

F2. Si $A \in F \Rightarrow A^c \in F$.

F3. Si $A_i \in F \Rightarrow \bigcup_{i=0}^{\infty} A_i \in F$.

P1. $P(S) = 1$.

P2. Si $A_i \in F$ son disjuntos entonces $P\left(\bigcup_{i=0}^{\infty} A_i\right) = \sum_{i=0}^{\infty} P(A_i)$.

El trio (S, F, P) se llama **espacio de probabilidad**.

Concepto de probabilidad - Espacios discretos - Ejemplo

Supongamos que lanzamos dos dados y queremos hacer mediciones sobre los resultados.

Concepto de probabilidad - Espacios discretos - Ejemplo

Supongamos que lanzamos dos dados y queremos hacer mediciones sobre los resultados.

Podemos modelar como:

$$S = \{(1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (1, 6), \\ (2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), \\ (3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6), \\ (4, 1), (4, 2), (4, 3), (4, 4), (4, 5), (4, 6), \\ (5, 1), (5, 2), (5, 3), (5, 4), (5, 5), (5, 6), \\ (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6)\}$$

$$\text{y } P((i, j)) = \frac{1}{36}.$$

Concepto de probabilidad - Espacios discretos - Ejemplo

Supongamos que lanzamos dos dados y queremos hacer mediciones sobre los resultados.

Podemos modelar como:

$$S = \{(1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (1, 6), \\ (2, 1), (2, 2), (2, 3), (2, 4), (2, 5), (2, 6), \\ (3, 1), (3, 2), (3, 3), (3, 4), (3, 5), (3, 6), \\ (4, 1), (4, 2), (4, 3), (4, 4), (4, 5), (4, 6), \\ (5, 1), (5, 2), (5, 3), (5, 4), (5, 5), (5, 6), \\ (6, 1), (6, 2), (6, 3), (6, 4), (6, 5), (6, 6)\}$$

$$\text{y } P((i, j)) = \frac{1}{36}.$$

Un espacio de probabilidad con S finito* se llama **discreto**.

**O con un subconjunto finito de probabilidad 1.*

Concepto de probabilidad - Espacios discretos - Ejemplo

Se pueden responder preguntas sobre la probabilidad de que sucedan distintos **eventos**:

- a. Cual es la probabilidad de sacar un 6 y un 2, en ese orden?
- b. Cual es la probabilidad de sacar un 6 y un 2?
- c. Cual es la probabilidad de sacar dos 5?
- d. Cual es la probabilidad de sacar dos números iguales?
- e. Cual es la probabilidad de que los números elegidos sumen 7?
- f. Cual es la probabilidad de que los números elegidos sumen 2?
- g. Cual es la probabilidad de sacar un número par y un número impar?

Notación: usualmente denotaremos a los eventos con una letra. Ejemplo: si $A = \{\text{los dados suman 7}\}$ entonces $P(A) = 6/36 = 1/6$.

Concepto de probabilidad - Espacios continuos

Supongamos que queremos entender la temperatura en el mundo.

Podríamos definir $S = \mathbb{R}$ el espacio de posibles temperaturas.

Concepto de probabilidad - Espacios continuos

Supongamos que queremos entender la temperatura en el mundo.

Podríamos definir $S = \mathbb{R}$ el espacio de posibles temperaturas.

También podríamos modelar $S = (\mathbb{R} \times \mathbb{R}) \times \mathbb{R}_{>0} \times \mathbb{R}$.

Coordenadas
(espacio)

Tiempo Temperatura

Concepto de probabilidad - Espacios continuos

Supongamos que queremos entender la temperatura en el mundo.

Podríamos definir $S = \mathbb{R}$ el espacio de posibles temperaturas.

También podríamos modelar $S = (\mathbb{R} \times \mathbb{R}) \times \mathbb{R}_{>0} \times \mathbb{R}$.

Coordenadas
(espacio)

Tiempo

Temperatura

En este caso, cuál debería ser la probabilidad de observar una temperatura particular?

Un espacio que no es discreto se llama **continuo**.

Probabilidad condicional - Definición


Un concepto importante es la **probabilidad condicional**. Es una forma de medir la probabilidad de que ocurra un evento dado que otro ocurrió.

Probabilidad condicional - Definición

Un concepto importante es la **probabilidad condicional**. Es una forma de medir la probabilidad de que ocurra un evento dado que otro ocurrió.

Formalmente se define como:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$




$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Probabilidad condicional - Definición

Un concepto importante es la **probabilidad condicional**. Es una forma de medir la probabilidad de que ocurra un evento dado que otro ocurrió.

Formalmente se define como:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$



$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Intuitivamente es el resultado de restringir el espacio muestral a B y medir la probabilidad de que A ocurra allí dentro. Un resultado intuitivo es el siguiente:

$$P(B) = P(B|A)P(A) + P(B|A^c)P(A^c)$$

Probabilidad condicional - Ejemplos

En el ejemplo de los dos dados:

- Cual es la probabilidad de que los dados sumen 6 dado que ambos son impares?

Probabilidad condicional - Ejemplos

En el ejemplo de los dos dados:

- Cual es la probabilidad de que los dados sumen 6 dado que ambos son impares?
 - $A = \{\text{los dados suman } 6\} = \{(1,5), (2,4), (3,3), (4,2), (5,1)\}$
 - $B = \{\text{ambos dados son impares}\} = \{\dots\}$
 - $A \cap B = \{\text{los dados suman } 6 \text{ y son impares}\} = \{(1,5), (3,3), (5,1)\}$

Probabilidad condicional - Ejemplos

En el ejemplo de los dos dados:

- Cual es la probabilidad de que los dados sumen 6 dado que ambos son impares?
 - $A = \{\text{los dados suman } 6\} = \{(1,5), (2,4), (3,3), (4,2), (5,1)\}$
 - $B = \{\text{ambos dados son impares}\} = \{\dots\}$
 - $A \cap B = \{\text{los dados suman } 6 \text{ y son impares}\} = \{(1,5), (3,3), (5,1)\}$

Entonces $P(A) = \frac{5}{36}$, $P(B) = \frac{9}{36}$, $P(A \cap B) = \frac{3}{36}$, luego:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{3/36}{9/36} = \frac{1}{3}$$

Probabilidad condicional - Ejemplos

En el ejemplo de los dos dados:

- Cual es la probabilidad de que los dados sumen 6 dado que ambos son impares?
 - $A = \{\text{los dados suman } 6\} = \{(1,5), (2,4), (3,3), (4,2), (5,1)\}$
 - $B = \{\text{ambos dados son impares}\} = \{\dots\}$
 - $A \cap B = \{\text{los dados suman } 6 \text{ y son impares}\} = \{(1,5), (3,3), (5,1)\}$

Entonces $P(A) = \frac{5}{36}$, $P(B) = \frac{9}{36}$, $P(A \cap B) = \frac{3}{36}$, luego:

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{3/36}{9/36} = \frac{1}{3}$$

- Cual es la probabilidad de que los dados sumen 7 dado que ambos son impares?

Probabilidad condicional - Bayes

[Bayes] Si A y B son eventos y la probabilidad de B no es 0, entonces:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Probabilidad condicional - Bayes

[Bayes] Si A y B son eventos y la probabilidad de B no es 0, entonces:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Ejemplo clásico:

Un test para una enfermedad tiene confiabilidad del 99% (detecta correctamente 99% de casos positivos y negativos). El 1% de la población posee la enfermedad. Si un individuo testea positivo, cuál es la probabilidad de que tenga la enfermedad?

Probabilidad condicional - Bayes

[Bayes] Si A y B son eventos y la probabilidad de B no es 0, entonces:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Ejemplo clásico:

Un test para una enfermedad tiene confiabilidad del 99% (detecta correctamente 99% de casos positivos y negativos). El 1% de la población posee la enfermedad. Si un individuo testea positivo, cuál es la probabilidad de que tenga la enfermedad?

B = el test es positivo, A = el individuo tiene la enfermedad.

Probabilidad condicional - Bayes

[Bayes] Si A y B son eventos y la probabilidad de B no es 0, entonces:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Ejemplo clásico:

Un test para una enfermedad tiene confiabilidad del 99% (detecta correctamente 99% de casos positivos y negativos). El 1% de la población posee la enfermedad. Si un individuo testea positivo, cuál es la probabilidad de que tenga la enfermedad?

B = el test es positivo, A = el individuo tiene la enfermedad.

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|A^c)P(A^c)}$$

Probabilidad condicional - Bayes

[Bayes] Si A y B son eventos y la probabilidad de B no es 0, entonces:

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Ejemplo clásico:

Un test para una enfermedad tiene confiabilidad del 99% (detecta correctamente 99% de casos positivos y negativos). El 1% de la población posee la enfermedad. Si un individuo testea positivo, cuál es la probabilidad de que tenga la enfermedad?

B = el test es positivo, A = el individuo tiene la enfermedad.

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \frac{P(B|A)P(A)}{P(B|A)P(A) + P(B|A^c)P(A^c)} = \frac{0.99 \cdot 0.01}{0.0198} = 0.5$$

Variables aleatorias

Hasta ahora definimos S como el universo de cosas que nos interesa medir y trabajamos con eventos.

En la teoría de probabilidad las **variables aleatorias** representan mediciones a valores reales que se toman sobre el espacio de probabilidad.

Variables aleatorias

Hasta ahora definimos S como el universo de cosas que nos interesa medir y trabajamos con eventos.

En la teoría de probabilidad las **variables aleatorias** representan mediciones a valores reales que se toman sobre el espacio de probabilidad.

Formalmente, una variable aleatoria X es una función

$$X : S \rightarrow \mathbb{R}$$

que cumple que para todo intervalo de números reales se puede calcular la probabilidad de $X^{-1}([a, b])$.

Variables aleatorias

Hasta ahora definimos S como el universo de cosas que nos interesa medir y trabajamos con eventos.

En la teoría de probabilidad las **variables aleatorias** representan mediciones a valores reales que se toman sobre el espacio de probabilidad.

Formalmente, una variable aleatoria X es una función

$$X : S \rightarrow \mathbb{R}$$

que cumple que para todo intervalo de números reales se puede calcular la probabilidad de $X^{-1}([a, b])$.

Ejemplos:

- X = la suma de dos dados.
- Y = la temperatura a las 12AM de un día.
- Z = el peso de un bebé recién nacido.

Variables aleatorias

Hasta ahora definimos S como el universo de cosas que nos interesa medir y trabajamos con eventos.

En la teoría de probabilidad las **variables aleatorias** representan mediciones a valores reales que se toman sobre el espacio de probabilidad.

Formalmente, una variable aleatoria X es una función

$$X : S \rightarrow \mathbb{R}$$

que cumple que para todo intervalo de números reales se puede calcular la probabilidad de $X^{-1}([a, b])$.

Ejemplos:

- X = la suma de dos dados.
- Y = la temperatura a las 12AM de un día.
- Z = el peso de un bebé recién nacido.

Abuso: observemos que muchas veces cometemos el abuso de no especificar cuál es el espacio S .

Variables aleatorias

- Una variable aleatoria se dice **discreta** si toma una cantidad finita* de valores.

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Variables aleatorias

- Una variable aleatoria se dice **discreta** si toma una cantidad finita* de valores.
- Una variable aleatoria se dice **continua** si tiene una función de densidad, es decir una f tal que:

$$P(X \in [a, b]) = \int_a^b f(x)dx$$

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Variables aleatorias

- Una variable aleatoria se dice **discreta** si toma una cantidad finita* de valores.
- Una variable aleatoria se dice **continua** si tiene una función de densidad, es decir una f tal que:

$$P(X \in [a, b]) = \int_a^b f(x)dx$$

- En caso contrario se dice **mixta** (pero probablemente no analicemos ningún caso de este estilo en este curso).

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Variables aleatorias

- Una variable aleatoria se dice **discreta** si toma una cantidad finita* de valores.
- Una variable aleatoria se dice **continua** si tiene una función de densidad, es decir una f tal que:

$$P(X \in [a, b]) = \int_a^b f(x)dx$$

- En caso contrario se dice **mixta** (pero probablemente no analicemos ningún caso de este estilo en este curso).

En nuestros ejemplos X es discreta, mientras lo más sensato es modelar a Y y Z como variables continuas.

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Variables aleatorias

- Una variable aleatoria se dice **discreta** si toma una cantidad finita* de valores.
- Una variable aleatoria se dice **continua** si tiene una función de densidad, es decir una f tal que:

$$P(X \in [a, b]) = \int_a^b f(x)dx$$

- En caso contrario se dice **mixta** (pero probablemente no analicemos ningún caso de este estilo en este curso).

En nuestros ejemplos X es discreta, mientras lo más sensato es modelar a Y y Z como variables continuas.

Definicion: Dada una variable aleatoria X definimos su función de distribución acumulada como:

$$F_X(\alpha) = P(X < \alpha)$$

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Vectores aleatorios

Un **vector aleatorio** es una tupla de variables aleatorias (X_1, X_2, \dots, X_n) .

Vectores aleatorios

Un **vector aleatorio** es una tupla de variables aleatorias (X_1, X_2, \dots, X_n) .

Definiciones en 2 variables:

- Un vector aleatorio (X, Y) se dice discreto si toma una cantidad finita* de valores.
- Un vector aleatorio se dice continuo si tiene una densidad, es decir una función tal que:

$$P((X, Y) \in A) = \int_A f_{X,Y}(x, y) \, dx dy$$

para cualquier *caja* A .

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Vectores aleatorios

Un **vector aleatorio** es una tupla de variables aleatorias (X_1, X_2, \dots, X_n) .

Definiciones en 2 variables:

- Un vector aleatorio (X, Y) se dice discreto si toma una cantidad finita* de valores.
- Un vector aleatorio se dice continuo si tiene una densidad, es decir una función tal que:

$$P((X, Y) \in A) = \int_A f_{X,Y}(x, y) \, dx dy$$

para cualquier *caja* A .

Para un vector aleatorio continuo podemos calcular la probabilidad de que (X, Y) se encuentre dentro de una región como la integral de la densidad sobre esa región.

*o numerable. En mayor deatalle, si hay una cantidad finita de valores que toma con probabilidad 1.

Vectores aleatorios


Ejemplo:

Si tomamos dos números x , y al azar en el intervalo $[0,1]$, cuál es la probabilidad de que $x+y$ sea mayor a 1?

Idea:

- Considerar (X, Y) un vector aleatorio con densidad f igual a 1 en el $[0,1] \times [0,1]$ y 0 fuera.
- Queremos calcular:

$$P(X + Y < 1) = P((X, Y) \in A) = \int_A 1 \, dx dy = \frac{1}{2}$$



Esperanza, Varianza, Covarianza

Un valor importante es la **esperanza** de una variable aleatoria. Es el **valor esperado o promedio** del experimento.

- Para una variable **discreta** definimos:

$$\mathbb{E}(X) = \sum_i P(X = x_i)x_i$$

- Mientras que para una **continua** resulta:

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f_X(x) dx$$

Esperanza, Varianza, Covarianza

Algunos ejemplos:

- $X = \{\text{la suma de 2 dados}\}$

$$\begin{aligned}\mathbb{E}(X) &= P(X = 2) \cdot 2 + P(X = 3) \cdot 3 + \dots + P(X = 12) \cdot 12 = \\ &= \frac{1}{36}(2 + 12) + \frac{2}{36}(3 + 11) + \frac{3}{36}(4 + 10) + \frac{4}{36}(5 + 9) + \frac{5}{36}(6 + 8) + \frac{6}{36}(7) = 7\end{aligned}$$

Esperanza, Varianza, Covarianza

Algunos ejemplos:

- $X = \{\text{la suma de 2 dados}\}$

$$\begin{aligned}\mathbb{E}(X) &= P(X = 2) \cdot 2 + P(X = 3) \cdot 3 + \dots + P(X = 12) \cdot 12 = \\ &= \frac{1}{36}(2 + 12) + \frac{2}{36}(3 + 11) + \frac{3}{36}(4 + 10) + \frac{4}{36}(5 + 9) + \frac{5}{36}(6 + 8) + \frac{6}{36}(7) = 7\end{aligned}$$

- $W = \{\text{el máximo de dos dados}\}$

$$E(W) = 6 \cdot \frac{11}{36} + 4 \cdot \frac{9}{36} + 4 \cdot \frac{7}{36} + 3 \cdot \frac{5}{36} + 2 \cdot \frac{3}{36} + 1 \cdot \frac{1}{36} = 4.472 \dots$$

Esperanza, Varianza, Covarianza

Algunos ejemplos:

- $X = \{\text{la suma de 2 dados}\}$

$$\begin{aligned}\mathbb{E}(X) &= P(X = 2) \cdot 2 + P(X = 3) \cdot 3 + \dots + P(X = 12) \cdot 12 = \\ &= \frac{1}{36}(2 + 12) + \frac{2}{36}(3 + 11) + \frac{3}{36}(4 + 10) + \frac{4}{36}(5 + 9) + \frac{5}{36}(6 + 8) + \frac{6}{36}(7) = 7\end{aligned}$$

- $W = \{\text{el máximo de dos dados}\}$

$$E(W) = 6 \cdot \frac{11}{36} + 4 \cdot \frac{9}{36} + 4 \cdot \frac{7}{36} + 3 \cdot \frac{5}{36} + 2 \cdot \frac{3}{36} + 1 \cdot \frac{1}{36} = 4.472 \dots$$

- $Y = \{\text{la cantidad de caras obtenidas al tirar una moneda 4 veces}\}$

Esperanza, Varianza, Covarianza

Algunos ejemplos:

- $X = \{\text{la suma de 2 dados}\}$

$$\begin{aligned}\mathbb{E}(X) &= P(X = 2) \cdot 2 + P(X = 3) \cdot 3 + \dots + P(X = 12) \cdot 12 = \\ &= \frac{1}{36}(2 + 12) + \frac{2}{36}(3 + 11) + \frac{3}{36}(4 + 10) + \frac{4}{36}(5 + 9) + \frac{5}{36}(6 + 8) + \frac{6}{36}(7) = 7\end{aligned}$$

- $W = \{\text{el máximo de dos dados}\}$

$$E(W) = 6 \cdot \frac{11}{36} + 4 \cdot \frac{9}{36} + 4 \cdot \frac{7}{36} + 3 \cdot \frac{5}{36} + 2 \cdot \frac{3}{36} + 1 \cdot \frac{1}{36} = 4.472 \dots$$

- $Y = \{\text{la cantidad de caras obtenidas al tirar una moneda 4 veces}\}$
- $Z = \{\text{la altura de un bebé recién nacido}\}$

Esperanza, Varianza, Covarianza

- La **varianza** y el **desvío estándar** de X :

$$Var(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

$$\sigma(X) = \sqrt{Var(X)}$$

- Si Y es otra variable aleatoria en el mismo espacio de probabilidad, la **covarianza** y la **correlación** entre X e Y :

$$Cov(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

$$corr(X, Y) = \frac{Cov(X, Y)}{\sigma(X)\sigma(Y)}$$

Esperanza, Varianza, Covarianza

- La **varianza** y el **desvío estándar** de X :

$$Var(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

$$\sigma(X) = \sqrt{Var(X)}$$

- Si Y es otra variable aleatoria en el mismo espacio de probabilidad, la **covarianza** y la **correlación** entre X e Y :

$$Cov(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

$$corr(X, Y) = \frac{Cov(X, Y)}{\sigma(X)\sigma(Y)}$$

Ejemplos:

- $X = \{\text{la suma de dos dados}\}$, $Y = \{\text{el doble del valor obtenido al tirar un dado}\}$.

Esperanza, Varianza, Covarianza

- La **varianza** y el **desvío estándar** de X :

$$Var(X) = \mathbb{E}((X - \mathbb{E}(X))^2)$$

$$\sigma(X) = \sqrt{Var(X)}$$


- Si Y es otra variable aleatoria en el mismo espacio de probabilidad, la **covarianza** y la **correlación** entre X e Y :

$$Cov(X, Y) = \mathbb{E}((X - \mathbb{E}(X))(Y - \mathbb{E}(Y)))$$

$$corr(X, Y) = \frac{Cov(X, Y)}{\sigma(X)\sigma(Y)}$$

Ejemplos:

- $X = \{\text{la suma de dos dados}\}$, $Y = \{\text{el doble del valor obtenido al tirar un dado}\}$.



Esperanza, Varianza, Covarianza

Propiedades:

- La esperanza es lineal:

$$\begin{cases} \mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y) \\ \mathbb{E}(cX) = c\mathbb{E}(X) \end{cases}$$

- Varianza:

$$Var(X) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

$$Var(cX) = c^2 Var(X)$$

- Covarianza:

$$cov(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

$$Var(X + Y) = Var(X) + Var(Y) + 2cov(X, Y)$$

Distribuciones

- Dos variables aleatorias tienen la misma distribución, si sus funciones de distribución acumuladas son iguales.
- Esto permite abstraerse definitivamente del espacio muestral y hablar directamente de distribuciones.

Distribuciones

- Dos variables aleatorias tienen la misma distribución, si sus funciones de distribución acumuladas son iguales.
- Esto permite abstraerse definitivamente del espacio muestral y hablar directamente de distribuciones.

Ejemplos:


- Una variable aleatoria continua con función de densidad

$$f_X(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

tiene distribución Normal con media 0 y desvío 1. Se denota $X \sim \mathcal{N}(0, 1)$.

Distribuciones

Si X tiene distribución normal 0,1 entonces $\mathbb{E}(X) = 0$ y $Var(X) = 1$.



Distribuciones

Otros ejemplos notables:

- [Bernoulli] $Ber(p)$: evento binario. Vale 1 con probabilidad p y 0 con probabilidad $1-p$.
- [Binomial] $Bin(n, p)$: cantidad de resultados positivos en n repeticiones de un evento $Ber(p)$.
- [Geometrica] $\mathcal{G}(p)$: cantidad de repeticiones de un evento $Ber(p)$ hasta obtener el primer positivo.
- [Poisson] $Poisson(\lambda)$: cantidad de ocurrencias de un evento de Poisson en un intervalo de tiempo.

Distribuciones

Otros ejemplos notables:

- [Exponencial] $\exp(\lambda)$: tiempo hasta la primera ocurrencia de un evento de Poisson.
- [Uniforme] $\mathcal{U}([a, b])$: distribución que le da la misma probabilidad a todos los puntos de un segmento.
- [Normal] $\mathcal{N}(\mu, \sigma)$: variable igual a $\mu + \sigma Z$ con $Z \sim \mathcal{N}(0, 1)$.
- [Lognormal] $\text{Lognormal}(\mu, \sigma)$: variable aleatoria cuyo logaritmo es $\mathcal{N}(\mu, \sigma)$.
- [Normal multivariada] $\mathcal{N}(\mu, \Sigma)$: es un vector aleatorio continuo con función de densidad:

$$f_X(x) = (2\pi)^{-\frac{k}{2}} \det(\Sigma)^{-\frac{1}{2}} e^{-\frac{1}{2}(x-\mu)^t \Sigma (x-\mu)}$$

Lognormal como modelo de asset pricing

Supongamos un precio de un asset S . Nos interesa entender su retorno relativo:

$$\frac{S(t + \delta t) - S(t)}{\delta t S(t)}$$

Lognormal como modelo de asset pricing

Supongamos un precio de un asset S . Nos interesa entender su retorno relativo:

$$\frac{S(t + \delta t) - S(t)}{\delta t S(t)}$$

Si asumimos [mal!] que este asset tiene un retorno constante en el tiempo tendríamos:

$$\frac{S(t + \delta t) - S(t)}{\delta t S(t)} = \mu \longrightarrow S'(t) = \mu S(t)$$

Ya conocemos una ecuación parecida, que da como resultado $S(t) = S(0)e^{\mu t}$.

Lognormal como modelo de asset pricing

Supongamos un precio de un asset S . Nos interesa entender su retorno relativo:

$$\frac{S(t + \delta t) - S(t)}{\delta t S(t)}$$

Si asumimos [mal!] que este asset tiene un retorno constante en el tiempo tendríamos:

$$\frac{S(t + \delta t) - S(t)}{\delta t S(t)} = \mu \longrightarrow S'(t) = \mu S(t)$$

Ya conocemos una ecuación parecida, que da como resultado $S(t) = S(0)e^{\mu t}$.

Una asunción más razonable es:

$$\frac{S(t + \delta t) - S(t)}{\delta t S(t)} = \mu + \sigma \frac{1}{\sqrt{\delta t}} Z \sim N(\mu, \tilde{\sigma})$$

Análogamente a la ecuación de retorno fijo esto implica que S tiene distribución lognormal.

Independencia

Dos eventos A y B se dicen independientes si

$$P(B|A) = P(B)$$

Esto equivale a

$$P(A|B) = P(A) \text{ y } P(A \cap B) = P(A)P(B)$$

Dos eventos son independientes cuando saber que uno sucedió no afecta la probabilidad de que el otro suceda.

Independencia

Dos eventos A y B se dicen independientes si

$$P(B|A) = P(B)$$

Esto equivale a

$$P(A|B) = P(A) \text{ y } P(A \cap B) = P(A)P(B)$$

Dos eventos son independientes cuando saber que uno sucedió no afecta la probabilidad de que el otro suceda.

En nuestro ejemplo de los dos dados:

- $A = \{\text{el primer dado es igual a 1}\}$ y $B = \{\text{el segundo dado es igual a 1}\}$ son eventos independientes.
- $A = \{\text{la suma es par}\}$ y $B = \{\text{la suma es impar}\}$ **no** son eventos independientes.
- $A = \{\text{la suma es mayor a 9}\}$ y $B = \{\text{el primer dado es par}\}$ **no** son eventos independientes.

Independencia

Dos variables aleatorias X, Y son independientes si $X^{-1}([a, b])$ y $Y^{-1}([c, d])$ son eventos independientes para cualquier par de intervalos $[a, b]$ y $[c, d]$.

Independencia

Dos variables aleatorias X, Y son independientes si $X^{-1}([a, b])$ y $Y^{-1}([c, d])$ son eventos independientes para cualquier par de intervalos $[a, b]$ y $[c, d]$.

Intuición: dos experimentos son independientes si cualquier medición que conozcamos sobre uno de ellos no afecta la probabilidad de obtener otra medición sobre el otro.

Independencia

Dos variables aleatorias X, Y son independientes si $X^{-1}([a, b])$ y $Y^{-1}([c, d])$ son eventos independientes para cualquier par de intervalos $[a, b]$ y $[c, d]$.

Intuición: dos experimentos son independientes si cualquier medición que conozcamos sobre uno de ellos no afecta la probabilidad de obtener otra medición sobre el otro.

Importante: dos variables aleatorias independientes siempre van a tener covarianza igual a 0. El recíproco no es cierto.

Independencia

Ejemplos:

- En el ejemplo en el que lanzamos dos dados:
 - La suma de los dados y el máximo de los dados **NO** son independientes.
 - El valor del primer dado y el valor del segundo dado **SI** son independientes.

Independencia

Ejemplos:

- En el ejemplo en el que lanzamos dos dados:
 - La suma de los dados y el máximo de los dados **NO** son independientes.
 - El valor del primer dado y el valor del segundo dado **SI** son independientes.
- El peso y la altura de un recién nacido deberían ser modelados como variables aleatorias **NO** independientes.

Independencia

Si X e Y son variables aleatorias independientes:

- $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$
- $Var(X + Y) = Var(X) + Var(Y)$
- $cov(X, Y) = 0$

Independencia

Si X e Y son variables aleatorias independientes:

- $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$
- $Var(X + Y) = Var(X) + Var(Y)$
- $cov(X, Y) = 0$

Si X e Y son continuas e independientes entonces:

- $f_{XY}(x, y) = f_X(x)f_Y(y)$
- $f_{X+Y}(x) = (f_X * f_Y)(x) = \int_{-\infty}^{\infty} f_X(z)f_Y(x - z)dz$

Una consecuencia importante:

Si X e Y son dos variables aleatorias normales e independientes entonces $X+Y$ también tiene distribución normal.

La ley de los grandes números

[Ley de los grandes números] Dada una sucesión de variables aleatorias X_i , todas independientes, con esperanza finita y con la misma distribución (iid) vale que:

$$\frac{X_1 + X_2 + \dots + X_n}{n} \rightarrow \mathbb{E}(X_1)$$

cuando n tiende a infinito.

La ley de los grandes números

[Ley de los grandes números] Dada una sucesión de variables aleatorias X_i , todas independientes, con esperanza finita y con la misma distribución (iid) vale que:

$$\frac{X_1 + X_2 + \dots + X_n}{n} \rightarrow \mathbb{E}(X_1)$$

cuando n tiende a infinito.

Intuición

- La esperanza se puede interpretar como el “promedio de todos los posibles valores” que toma una variable aleatoria.
- La suma del lado izquierdo se puede interpretar como un promedio de infinitos valores de la misma variable aleatoria.

La ley de los grandes números

Ejemplos.


- Si lanzamos una moneda infinitas veces, la proporción de caras que obtengamos va a converger a 0.5.

La ley de los grandes números

Ejemplos.

- Si lanzamos una moneda infinitas veces, la proporción de caras que obtengamos va a converger a 0.5.
- Elegimos un punto al azar en $[0,1] \times [0,1]$ y sumamos 1 si cae debajo de la curva $y = x^2$ y 0 en caso contrario.

La proporción de 1s obtenida converge a la integral: $\int_0^1 x^2 dx$



La ley de los grandes números

“Demostración”: llamemos A a la región debajo de la curva $y = x^2$.

- Si $U \sim \mathcal{U}([0, 1] \times [0, 1])$ entonces la proporción de unos tiene que converger a la esperanza de la variable aleatoria V que vale 1 si $U \in A$ y 0 si no.

La ley de los grandes números

“Demostración”: llamemos A a la región debajo de la curva $y = x^2$.

- Si $U \sim \mathcal{U}([0, 1] \times [0, 1])$ entonces la proporción de unos tiene que converger a la esperanza de la variable aleatoria V que vale 1 si $U \in A$ y 0 si no.
- Vale que

$$\mathbb{E}(V) = 0 \cdot P(U \notin A) + 1 \cdot P(U \in A) = P(U \in A)$$

La ley de los grandes números

“Demostración”: llamemos A a la región debajo de la curva $y = x^2$.

- Si $U \sim \mathcal{U}([0, 1] \times [0, 1])$ entonces la proporción de unos tiene que converger a la esperanza de la variable aleatoria V que vale 1 si $U \in A$ y 0 si no.

- Vale que


$$\mathbb{E}(V) = 0 \cdot P(U \notin A) + 1 \cdot P(U \in A) = P(U \in A)$$

- Y además:

$$P(U \in A) = \int_A f_U(x, y) dx dy = \int_A 1 dx dy = \int_0^1 x^2 dx$$

La ley de los grandes números

- Esta idea se llama integración de Monte Carlo.
- En general, los métodos que utilizan simulaciones para aproximar una esperanza se llaman Métodos de Monte Carlo.
- Así como existen ecuaciones diferenciales que modelan precios de derivados, veremos que estos también se pueden interpretar como esperanzas de variables aleatorias.
- Los métodos Monte Carlo son muy versátiles, pero su convergencia suele ser *lenta*.



Teorema Central del Límite

[Teorema Central del Límite] Dada una sucesión de variables aleatorias X_i , todas independientes, con esperanza μ y varianza σ^2 y con la misma distribución (iid) llamemos

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Entonces cuando n tiende a infinito la distribución de

$$Z_n = \sqrt{n} \cdot \frac{\bar{X}_n - \mu}{\sigma}$$

Converge a una $\mathcal{N}(0, 1)$.

Teorema Central del Límite

[Teorema Central del Límite] Dada una sucesión de variables aleatorias X_i , todas independientes, con esperanza μ y varianza σ^2 y con la misma distribución (iid) llamemos

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Entonces cuando n tiende a infinito la distribución de

$$Z_n = \sqrt{n} \cdot \frac{\bar{X}_n - \mu}{\sigma}$$

Converge a una $\mathcal{N}(0, 1)$.







Intuición/Consecuencias

- No hay. Es un teorema medio mágico.
- La velocidad de convergencia de la Ley de los Grandes Números es $O\left(\frac{1}{\sqrt{n}}\right)$.

Teorema Central del Límite

Ejemplos







- Si tiramos n dados (para n grande) y calculamos la suma de los valores que obtuvimos entonces la distribución es aproximadamente normal.



Teorema Central del Límite

Ejemplos

- Si tiramos n dados (para n grande) y calculamos la suma de los valores que obtuvimos entonces la distribución es aproximadamente normal.
- Si tiramos una moneda 30 veces, cual es la probabilidad de obtener entre 10 y 20 caras? (aproximadamente)









Teorema Central del Límite

Ejemplos

- Si tiramos n dados (para n grande) y calculamos la suma de los valores que obtuvimos entonces la distribución es aproximadamente normal.
- Si tiramos una moneda 30 veces, cual es la probabilidad de obtener entre 10 y 20 caras? (aproximadamente)

Queremos saber $P(10 \leq X \leq 20)$ para $X = \text{Bin}(30, 0.5)$.
Observamos que

$$X = B_1 + \dots + B_{30}$$



Teorema Central del Límite

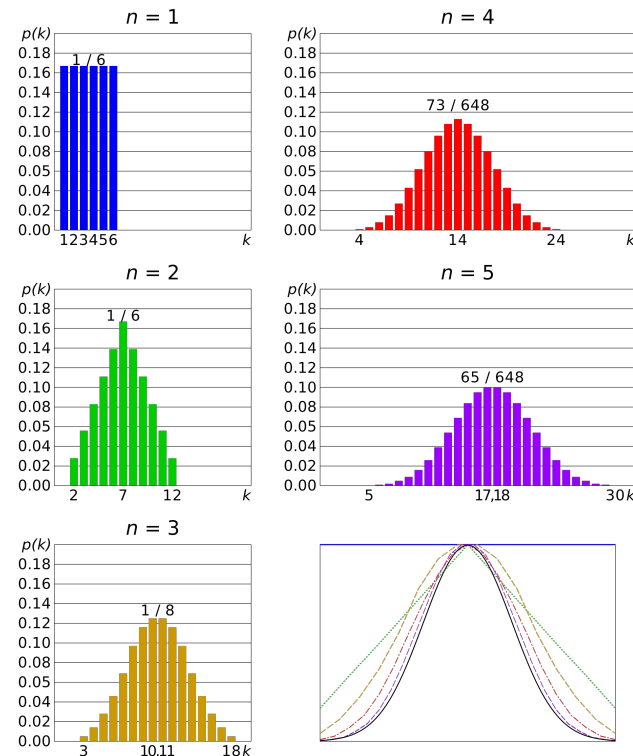
Ejemplos

- Si tiramos n dados (para n grande) y calculamos la suma de los valores que obtuvimos entonces la distribución es aproximadamente normal.
- Si tiramos una moneda 30 veces, cual es la probabilidad de obtener entre 10 y 20 caras? (aproximadamente)

Queremos saber $P(10 \leq X \leq 20)$ para $X = \text{Bin}(30, 0.5)$.
Observamos que

$$X = B_1 + \dots + B_{30}$$

Luego $Z = \sqrt{30} \cdot \frac{X/30 - 0.5}{0.25}$ tiene una distribución casi $\mathcal{N}(0, 1)$.



Teorema Central del Límite

En Machine Learning

- Tests estadísticos:
El TCL juega un papel fundamental en la mayoría de los tests estadísticos. Ejemplo más simple: Z-test.
- Estimaciones de errores:
Muchas estimaciones de parámetros se basan en tomar promedios. El TCL nos permite construir intervalos de error para esas estimaciones.
- Asunciones en modelos:
Muchos modelos asumen normalidad en distintas cantidades (ejemplo: una regresión lineal). En general esto se encuentra fuertemente influenciado por el TCL.

Esperanza condicional

Dadas X, Y variables aleatorias discretas definimos:

$$\mathbb{E}(X|Y = y) = \sum_x xP(X = x|Y = y) = \sum_x x \frac{p(x, y)}{p_Y(y)}$$

Es el valor esperado de X dada una observación de Y .

Esperanza condicional

Dadas X, Y variables aleatorias discretas definimos:

$$\mathbb{E}(X|Y = y) = \sum_x xP(X = x|Y = y) = \sum_x x \frac{p(x, y)}{p_Y(y)}$$

Es el valor esperado de X dada una observación de Y .

Ejemplo:

Si X e Y son Bernoulli, cual es el valor esperado de X si sabemos que $X+Y=1$?

Esperanza condicional

Dadas X, Y variables aleatorias discretas definimos:

$$\mathbb{E}(X|Y = y) = \sum_x xP(X = x|Y = y) = \sum_x x \frac{p(x, y)}{p_Y(y)}$$

Es el valor esperado de X dada una observación de Y .

Ejemplo:

Si X e Y son Bernoulli, cual es el valor esperado de X si sabemos que $X+Y=1$?

$$\mathbb{E}(X|X + Y = 1)$$

Esperanza condicional

Dadas X, Y variables aleatorias discretas definimos:

$$\mathbb{E}(X|Y = y) = \sum_x xP(X = x|Y = y) = \sum_x x \frac{p(x, y)}{p_Y(y)}$$

Es el valor esperado de X dada una observación de Y .

Ejemplo:

Si X e Y son Bernoulli, cual es el valor esperado de X si sabemos que $X+Y=1$?

$$\mathbb{E}(X|X + Y = 1) = 0P(X = 0|X + Y = 1) + 1P(X = 1|X + Y = 1)$$

Esperanza condicional

Dadas X, Y variables aleatorias discretas definimos:

$$\mathbb{E}(X|Y = y) = \sum_x xP(X = x|Y = y) = \sum_x x \frac{p(x, y)}{p_Y(y)}$$

Es el valor esperado de X dada una observación de Y .

Ejemplo:

Si X e Y son Bernoulli, cual es el valor esperado de X si sabemos que $X+Y=1$?

$$\mathbb{E}(X|X + Y = 1) = 0P(X = 0|X + Y = 1) + 1P(X = 1|X + Y = 1) = \frac{P(X = 1, X + Y = 1)}{P(X + Y = 1)}$$

Esperanza condicional

Dadas X, Y variables aleatorias discretas definimos:

$$\mathbb{E}(X|Y = y) = \sum_x xP(X = x|Y = y) = \sum_x x \frac{p(x, y)}{p_Y(y)}$$

Es el valor esperado de X dada una observación de Y .

Ejemplo:

Si X e Y son Bernoulli, cual es el valor esperado de X si sabemos que $X+Y=1$?

$$\mathbb{E}(X|X + Y = 1) = 0P(X = 0|X + Y = 1) + 1P(X = 1|X + Y = 1) = \frac{P(X = 1, X + Y = 1)}{P(X + Y = 1)} = \frac{1}{2}$$

Esperanza condicional

De la misma forma si X, Y son variables aleatorias continuas definimos la densidad condicional:

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

y la esperanza condicional:

$$\mathbb{E}(X|Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x) dx$$

Esperanza condicional

La **esperanza condicional** es la variable aleatoria $\mathbb{E}(X|Y)$ definida como

$$\mathbb{E}(X|Y)(y) = \mathbb{E}(X|Y = y)$$

Esperanza condicional

La **esperanza condicional** es la variable aleatoria $\mathbb{E}(X|Y)$ definida como

$$\mathbb{E}(X|Y)(y) = \mathbb{E}(X|Y = y)$$

La esperanza condicional es nuestro mejor estimado de X si conociéramos a Y , es de algún modo la variable que canaliza la regla para convertir un valor de Y en un estimado de X .

Esperanza condicional

La **esperanza condicional** es la variable aleatoria $\mathbb{E}(X|Y)$ definida como

$$\mathbb{E}(X|Y)(y) = \mathbb{E}(X|Y = y)$$

La esperanza condicional es nuestro [mejor estimado](#) de X si conociéramos a Y , es de algún modo la variable que canaliza la regla para convertir un valor de Y en un estimado de X .

Propiedades importantes:

- $\mathbb{E}(\mathbb{E}(X|Y)) = \mathbb{E}(X)$
- Lo que para variables discretas es $\mathbb{E}(X) = \sum_y \mathbb{E}(X|Y = y)P(Y = y)$
- Y para variables continuas es $\mathbb{E}(X) = \int_{-\infty}^{+\infty} \mathbb{E}(X|Y = y)f_Y(y)dy$

Esperanza condicional

Ejemplo: un trabajador está encerrado en una mina con 3 puertas.

- La primera puerta lleva a la salida en 3 horas.
- La segunda puerta lleva de vuelta a la mina en 5 horas.
- La tercera puerta lleva de vuelta a la mina en 7 horas.

Cual es el tiempo que en promedio debería llevar al trabajador salir de la mina?

Esperanza condicional

Ejemplo: un trabajador está encerrado en una mina con 3 puertas.

- La primera puerta lleva a la salida en 3 horas.
- La segunda puerta lleva de vuelta a la mina en 5 horas.
- La tercera puerta lleva de vuelta a la mina en 7 horas.

Cual es el tiempo que en promedio debería llevar al trabajador salir de la mina?

Si X = tiempo en salir de la mina e Y = puerta elegida inicialmente, entonces:

$$\mathbb{E}(X) = \mathbb{E}(X|Y = 1)P(Y = 1) + \mathbb{E}(X|Y = 2)P(Y = 2) + \mathbb{E}(X|Y = 3)P(Y = 3)$$

Esperanza condicional

Ejemplo: un trabajador está encerrado en una mina con 3 puertas.

- La primera puerta lleva a la salida en 3 horas.
- La segunda puerta lleva de vuelta a la mina en 5 horas.
- La tercera puerta lleva de vuelta a la mina en 7 horas.

Cual es el tiempo que en promedio debería llevar al trabajador salir de la mina?

Si X = tiempo en salir de la mina e Y = puerta elegida inicialmente, entonces:

$$\mathbb{E}(X) = \mathbb{E}(X|Y = 1)P(Y = 1) + \mathbb{E}(X|Y = 2)P(Y = 2) + \mathbb{E}(X|Y = 3)P(Y = 3)$$

Pero ademas:

- $\mathbb{E}(X|Y = 1) = 3$
- $\mathbb{E}(X|Y = 2) = 5 + \mathbb{E}(X)$
- $\mathbb{E}(X|Y = 3) = 7 + \mathbb{E}(X)$

Esperanza condicional

Ejemplo: un trabajador está encerrado en una mina con 3 puertas.

- La primera puerta lleva a la salida en 3 horas.
- La segunda puerta lleva de vuelta a la mina en 5 horas.
- La tercera puerta lleva de vuelta a la mina en 7 horas.

Cual es el tiempo que en promedio debería llevar al trabajador salir de la mina?

Si X = tiempo en salir de la mina e Y = puerta elegida inicialmente, entonces:

$$\mathbb{E}(X) = \mathbb{E}(X|Y = 1)P(Y = 1) + \mathbb{E}(X|Y = 2)P(Y = 2) + \mathbb{E}(X|Y = 3)P(Y = 3)$$

Pero ademas:

- $\mathbb{E}(X|Y = 1) = 3$
- $\mathbb{E}(X|Y = 2) = 5 + \mathbb{E}(X)$
- $\mathbb{E}(X|Y = 3) = 7 + \mathbb{E}(X)$

Lo que nos permite despejar $\mathbb{E}(X) = 15$